Projet semestriel 2026–2027 · Encadrant : Charles Brazier

Karaoké adaptatif

La chaîne de traitement imposée par le sujet



Temps réel

Le modèle ne peut pas attendre la fin.
Latence = frames futures qu'il attend.

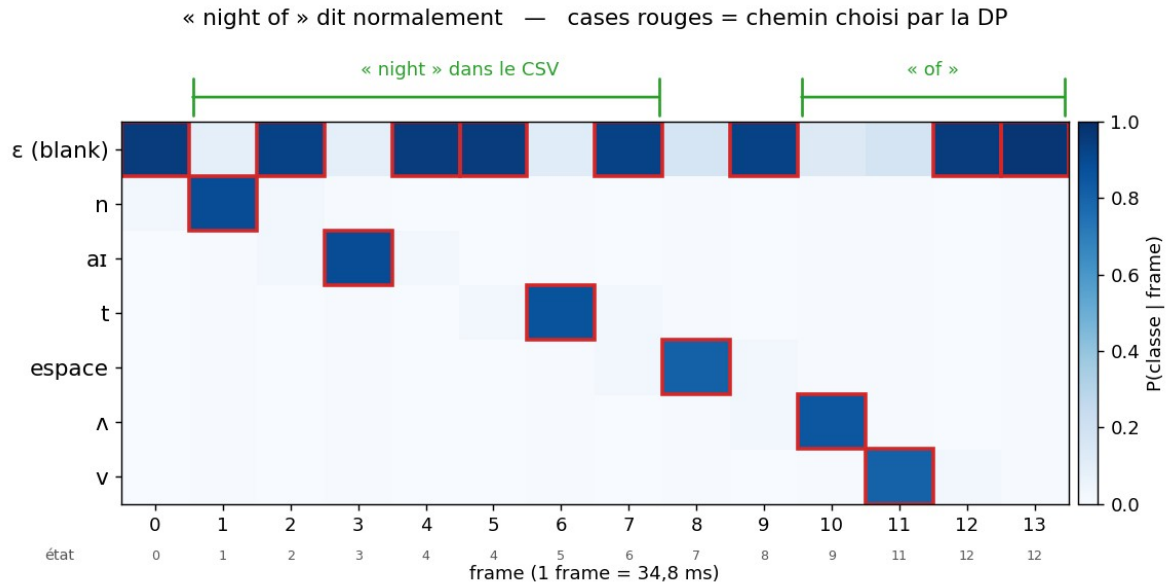
Ce que propose le sujet

Réseau léger : ResNet ou CRNN.
DTW temps réel fourni :
chant live ↔ référence.

Données

Entraînement : DALI v2.
Évaluation : Jamendo, MUSDB18.

Ce qu'on a compris : postériogramme et alignement



Exemple réel : « through » dans *Embers*

frame	934	935	936	937	938	939
état	1	3	5	6	6	7
symbole	**θ**	**ɹ**	**uː**	ε	ε	␣

Postériogramme

Matrice 72 × T : une probabilité par classe et par frame.
69 phonèmes, ␣, inconnu, blank ε.
1 frame = 3 × 11,6 ms ≈ 34,8 ms.

Paroles → tokens

Phonèmes de chaque mot, ␣ entre les mots : « night of » → n aɪ t ␣ ʌ v.
L tokens (800 sur *Embers*).

Alignement forcé

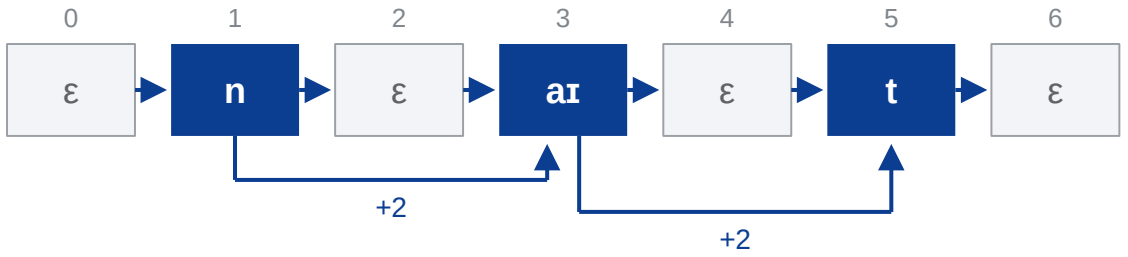
Programmation dynamique (CTC / Viterbi) : parmi toutes les façons de répartir les tokens sur les frames, dans l'ordre des paroles, elle garde la plus probable.

Résultat

Le token de chaque frame, donc le début et la fin de chaque mot (le CSV).

Alignement CTC : états et transitions

États pour « night » : L = 3 tokens → 2L + 1 = 7 états



À quoi servent les écarts ?

1. Retrouver le chemin, frame par frame.
2. Savoir à quelle frame commence chaque phonème. Pour un mot :
   - début : première frame sur son premier phonème ;
   - fin : première frame sur le ␣ qui suit.

#	mouvement	écart	sens	fréquence sur Embers
4	ε → même ε	**+0**	l'attente continue (tenue, silence, intro…)	**5 600**
5	ε → token suivant	**+1**	un nouveau son commence (le pic)	507
2	token → ε suivant	**+1**	le pic est fini, on entre dans l'attente	507
3	token → token suivant	**+2**	deux sons collés, sans attente entre eux	293
1	token → même token	**+0**	le même son déborde sur une frame de plus (pas une répétition)	56

Chemins observés (un symbole = une frame)

« night », normal	ε **n** ε **aɪ** ε ε **t** ε	1 phonème = 1 frame (93 % des cas).
« night », aɪ tenu ≈ 1 s	ε **n** ε **aɪ** ε×28 **t** ε	La tenue reste sur ε : aɪ émis une fois.
« through » (Embers)	ε ε ε **θ ɹ uː** ε ε ␣ ε **d**	3 sons collés : deux sauts +2.
silence après « of »	**ʌ v** ε×14 ␣ ε **n** ε **aɪ**	␣ juste avant « night » : silence compté dans « of ».

Ce qu'on compte faire

Modèle from scratch → DTW → comparaison au pré-entraîné.

1 · From scratch, sur DALI

1 Données

DALI v2, voix séparée.
Découpage train / val de jhuang448.

2 Spectrogrammes

Mel, via data.py de jhuang448.

3 Modèle causal

Peu ou pas de frames futures (latence).
Piste 1 : CRNN (Park et al., 2024).
Piste 2 : CP-ResNet (Brazier & Widmer, 2021).
Sortie : 72 classes.

4 Entraînement avec la CTC

Entrée : audio + phonèmes des paroles.
Pas besoin d'alignement par frame.

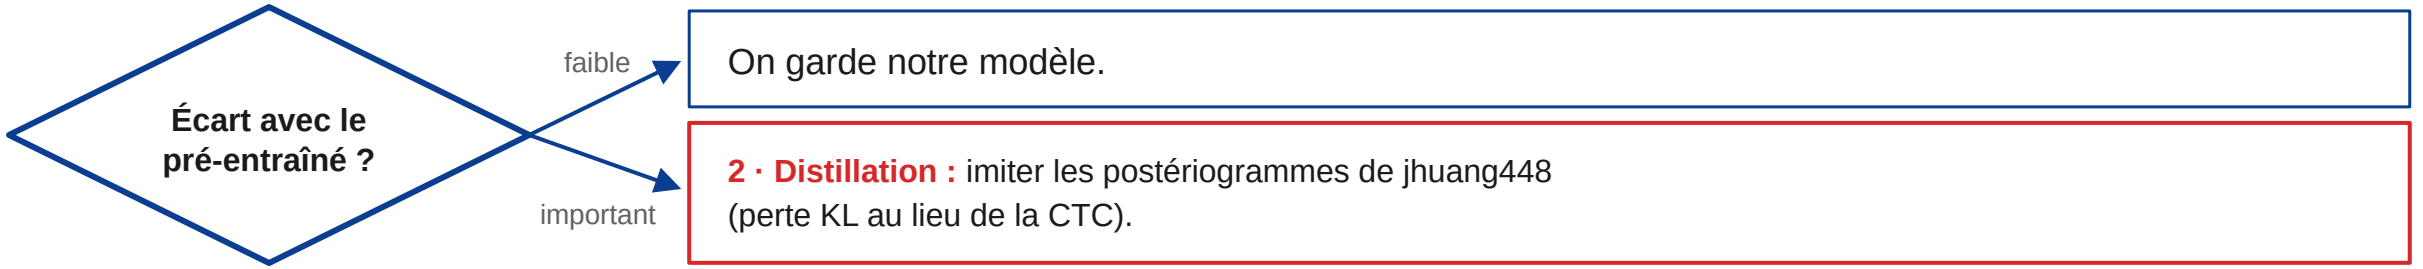
5 Postériogrammes

Sur les tests Jamendo et MUSDB.

6 Évaluation

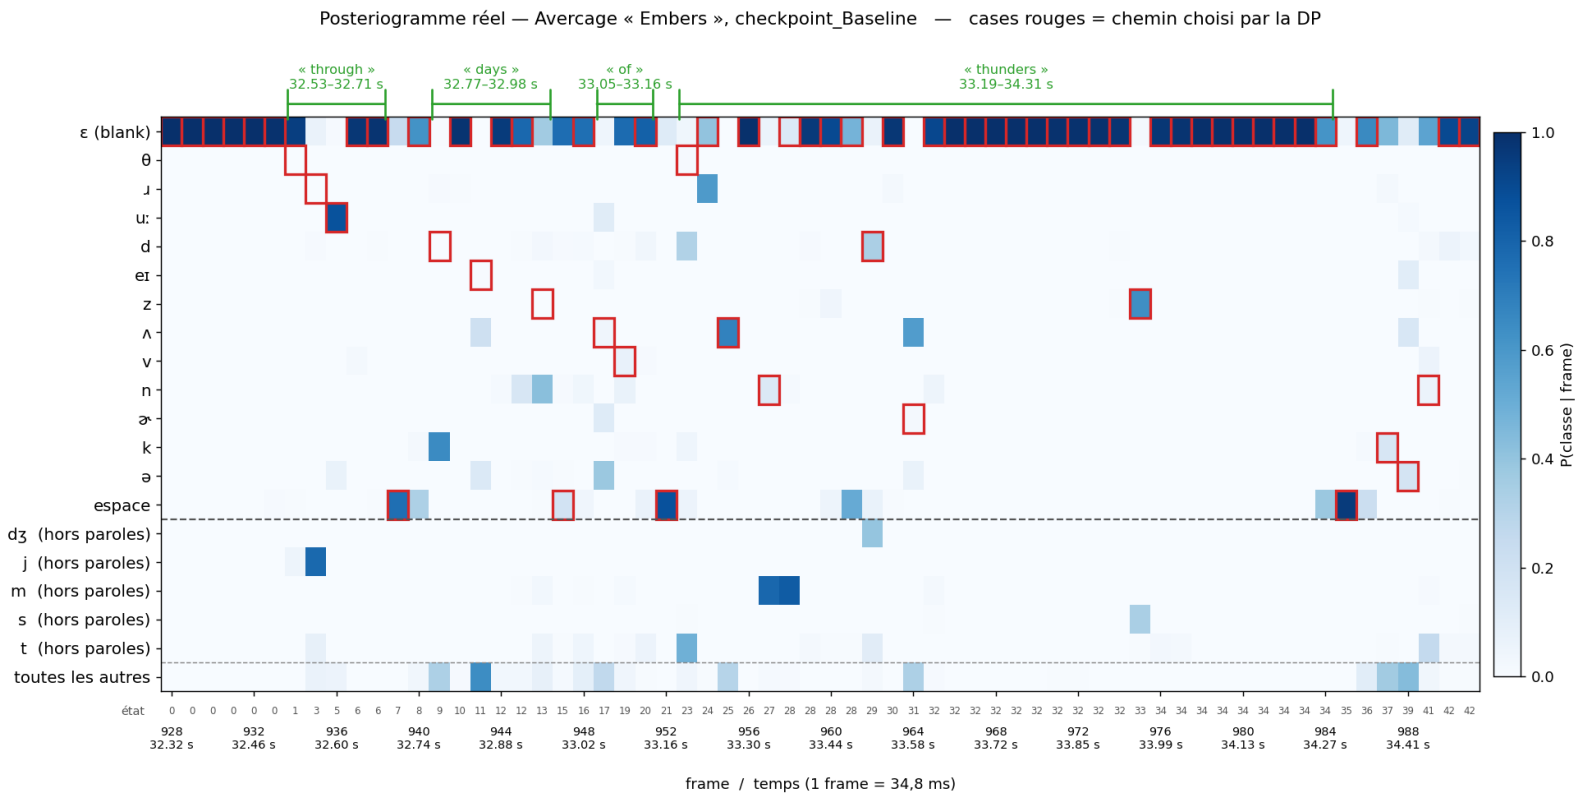
eval.py, face au pré-entraîné (checkpoint_Baseline).

Puis : brancher le **DTW temps réel** (fast_dtw.pyx) sur nos postériogrammes.



Premiers essais : le modèle pré-entraîné sur « Embers »

checkpoint_Baseline (jhuang448) sur une chanson Jamendo.



Bleu : prédiction du modèle (foncé = sûr).

Case rouge : phonème imposé par les paroles.

Rouge sur blanc : phonème attendu, non prédit.

Lignes « hors paroles » : prédit à la place (j au lieu de ɹ).

Accolade verte : début et fin de chaque mot.

91 %

des frames : ɛ est la classe la plus probable

93 %

des phonèmes durent une seule frame

30 %

seulement : le modèle met en premier le phonème attendu par les paroles

Ce qu'on en retient, et nos questions

Constats

Débuts de mots précis, fins trop longues

Début = pic du premier phonème : précis.
Fin = le ␣, mis juste avant le mot d'après,
donc le silence qui suit compte dedans.
→ on évaluera sur les débuts de mots.

Cet alignement attend la fin de la chanson

Il cherche le meilleur chemin sur toute la chanson, puis le remonte depuis la fin.
En karaoké, il faut la position à chaque instant → DTW temps réel (fourni).

Questions pour vous

1 Voix seule ou chanson entière ?

Séparer la voix avant le modèle (notre plan), ou entraîner sur le mix (Brazier & Widmer, 2021) ?

2 Aligner sur quoi ?

Sur la suite de phonèmes des paroles, ou sur un enregistrement de référence déjà annoté ?

3 Combien de frames futures ?

Attendre quelques frames après le son aide à le reconnaître, mais chaque phonème sort en retard (Brazier & Widmer, 2021 : 28 frames = 280 ms).

Où on en est

Fait : accès DALI v2, modèle pré-entraîné analysé.
Deux brouillons d'architecture.
Ensuite : télécharger DALI, entraîner from scratch.