Projet semestriel 2026–2027 · Encadrant : Charles Brazier

Karaoké adaptatif

La chaîne de traitement imposée par le sujet



Temps réel

Le modèle ne voit que le passé.
Latence = champ réceptif.

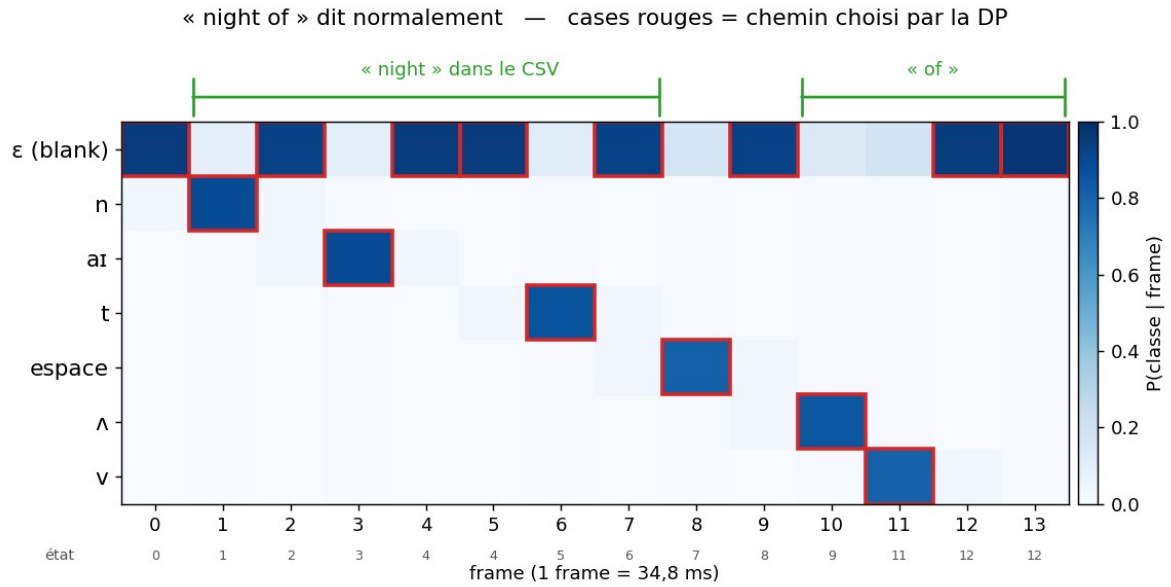
Ce que propose le sujet

Réseau léger : ResNet ou CRNN.
DTW temps réel fourni :
chant live ↔ référence.

Données

Entraînement : DALI v2.
Évaluation : Jamendo, MUSDB18.

Ce qu'on a compris : postériogramme et alignement



Exemple réel : « through » dans *Embers*

frame	934	935	936	937	938	939
état	1	3	5	6	6	7
symbole	**θ**	**ɹ**	**uː**	ε	ε	␣

Postériogramme

Matrice 72 × T : une probabilité par classe et par frame.
69 phonèmes, ␣, inconnu, blank ε.
1 frame = 3 × 11,6 ms ≈ 34,8 ms.

Paroles → tokens

Phonèmes de chaque mot, ␣ entre les mots : « night of » → n aɪ t ␣ ʌ v.
L tokens (800 sur *Embers*).

Alignement forcé

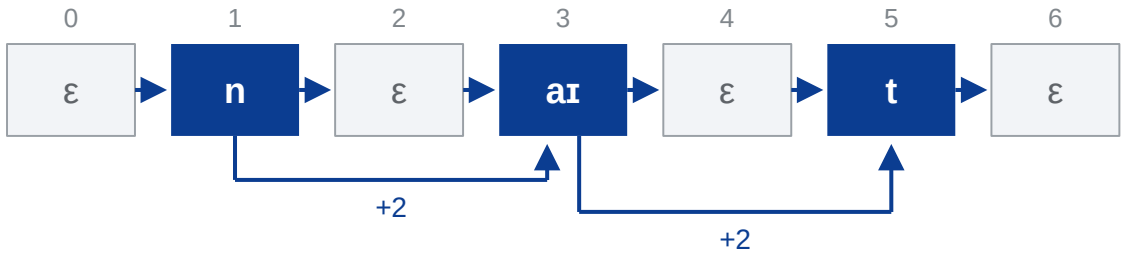
Programmation dynamique (CTC / Viterbi) : parmi toutes les façons de répartir les tokens sur les frames, dans l'ordre des paroles, elle garde la plus probable.

Résultat

Le token de chaque frame, donc le début et la fin de chaque mot (le CSV).

Alignement CTC : états et transitions

États pour « night » : L = 3 tokens → 2L + 1 = 7 états



À quoi servent les écarts ?

1. Retrouver le chemin, frame par frame.
2. Savoir à quelle frame commence chaque phonème. Pour un mot :
   - début : première frame sur son premier phonème ;
   - fin : première frame sur le ␣ qui suit.

#	mouvement	écart	sens	fréquence sur Embers
4	ε → même ε	**+0**	l'attente continue (tenue, silence, intro…)	**5 600**
5	ε → token suivant	**+1**	un nouveau son commence (le pic)	507
2	token → ε suivant	**+1**	le pic est fini, on entre dans l'attente	507
3	token → token suivant	**+2**	deux sons collés, sans attente entre eux	293
1	token → même token	**+0**	le même son déborde sur une frame de plus (pas une répétition)	56

Chemins observés (un symbole = une frame)

« night », normal	ε **n** ε **aɪ** ε ε **t** ε	1 phonème = 1 frame (93 % des cas).
« night », aɪ tenu ≈ 1 s	ε **n** ε **aɪ** ε×28 **t** ε	La tenue reste sur ε : aɪ émis une fois.
« through » (Embers)	ε ε ε **θ ɹ uː** ε ε ␣ ε **d**	3 sons collés : deux sauts +2.
silence après « of »	**ʌ v** ε×14 ␣ ε **n** ε **aɪ**	␣ juste avant « night » : silence compté dans « of ».

Ce qu'on compte faire

Modèle from scratch → DTW → comparaison au pré-entraîné.

1 · From scratch, sur DALI

1 Données

DALI v2, voix séparée.
Découpage train / val de jhuang448.

2 Spectrogrammes

Mel, via data.py de jhuang448.

3 Modèle causal

Ne voit que le passé (temps réel).
Piste 1 : CRNN, LSTM causal (Park).
Piste 2 : CP-ResNet (Brazier).
Sortie : 72 classes.

4 Entraînement avec la CTC

Entrée : audio + phonèmes des paroles.
Pas besoin d'alignement par frame.

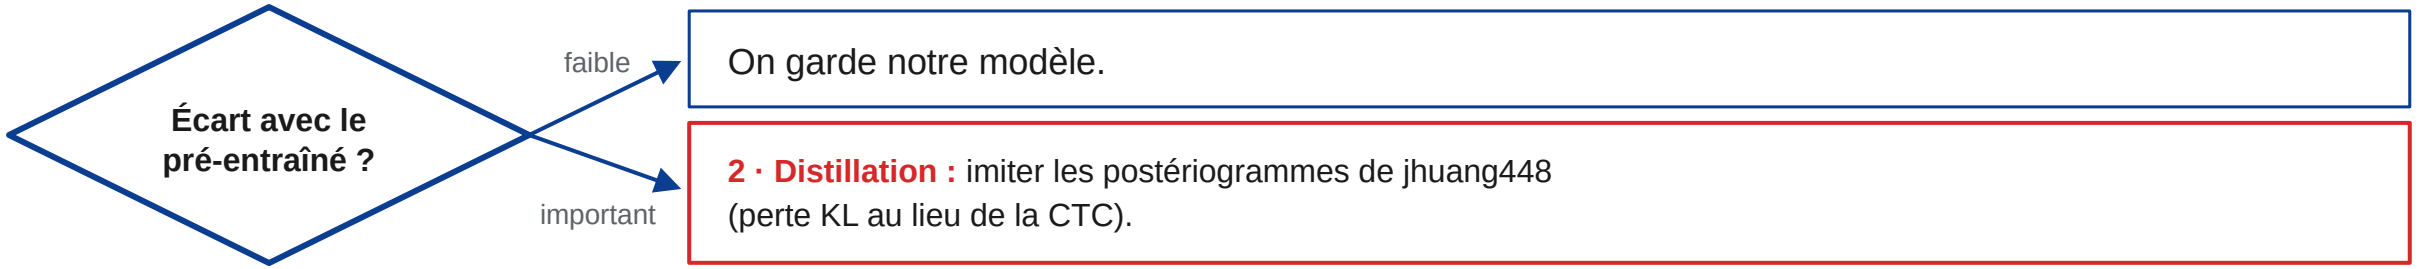
5 Postériogrammes

Sur les tests Jamendo et MUSDB.

6 Évaluation

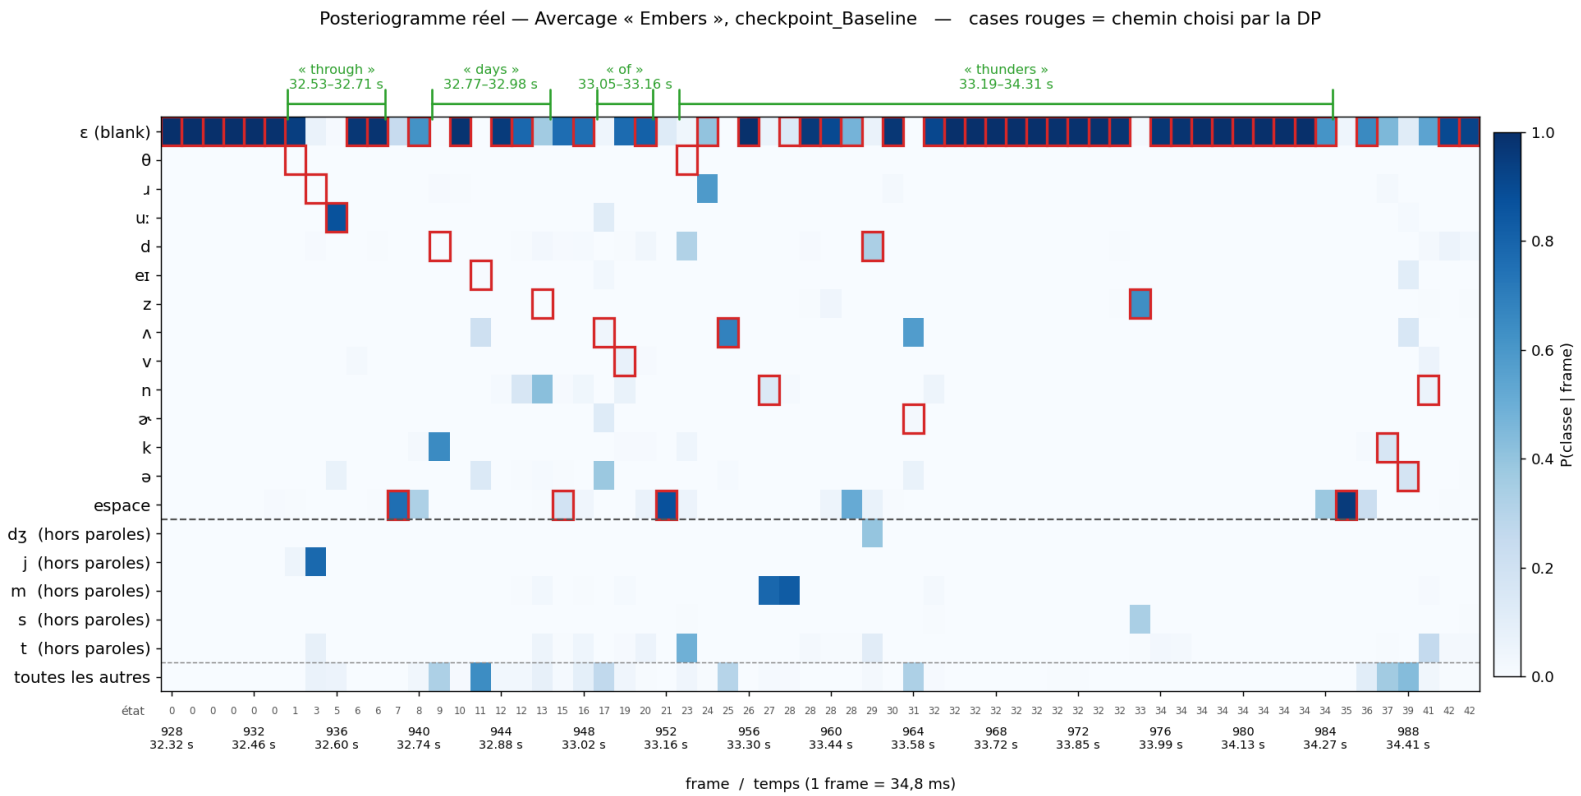
eval.py, face au pré-entraîné (checkpoint_Baseline).

Puis : brancher le **DTW temps réel** (fast_dtw.pyx) sur nos postériogrammes.



Premiers essais : le modèle pré-entraîné sur « Embers »

checkpoint_Baseline (jhuang448) sur une chanson Jamendo.



Bleu : prédiction du modèle (foncé = sûr).

Case rouge : phonème imposé par les paroles.

Rouge sur blanc : phonème attendu, non prédit.

Lignes « hors paroles » : prédit à la place (j au lieu de ɹ).

Accolade verte : début et fin de chaque mot.

91 %

des frames : ɛ est la classe la plus probable

93 %

des phonèmes durent une seule frame

30 %

seulement : le phonème imposé est l'argmax du modèle

Ce qu'on en retient, et nos questions

Constats

Débuts de mots fiables, fins gonflées

Le silence après un mot est compté dedans.
→ évaluer sur les débuts de mots.

Un bug dans utils.alignment

L'indice −1 fait repartir au premier phonème.
Correctif : saut seulement si ch_pos ≥ 3.

Cet alignement est hors ligne

Viterbi = toute la chanson.
→ il faudra un alignement en ligne.

Questions pour vous

1. Séparer la voix, ou entraîner sur le mix (Brazier & Widmer) ?
2. Aligner sur les paroles, ou sur une interprétation de référence ?
3. Quelle latence viser, donc quel champ réceptif ?

Où on en est

Fait : accès DALI v2, modèle pré-entraîné analysé.
Deux brouillons d'architecture.
Ensuite : télécharger DALI, entraîner from scratch.